

Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук

КУРСОВАЯ РАБОТА

Классификация на архитектуре GraphSAGE на основе АФП Classification using GraphSAGE and FCA

по направлению подготовки 01.04.02 Прикладная математика и информатика
образовательная программа «Науки о данных»

Студент группы МНКДН251
Хайрисламов Тимур Айдарович

Руководитель КР
Преподаватель, стажер-исследователь
Зуева Мария Михайловна

Москва, 2026

Содержание

Введение	3
1 Обзор связанных работ	7
1.1 Графовые нейронные сети и классификация узлов	7
1.2 FCA в машинном обучении и интерпретируемости	7
1.3 Нейронные сети на основе формальных понятий	8
1.4 Концептуальное шкалирование и числовые признаки	8
1.5 Размерностные контроли	9
2 Методология исследования	10
2.1 Постановка задачи	10
2.2 GraphSAGE	10
2.3 Построение формального контекста	11
2.4 Концептуальное шкалирование	11
2.5 Узорные структуры	12
2.6 Отбор понятий и FCA-признаки	12
2.7 SVD-контроль и протокол оценки	13
2.8 Воспроизводимость экспериментов	13
3 Экспериментальные результаты	14
3.1 Датасеты и базовые результаты	14
3.2 Структура формальных контекстов	15
3.3 Richer scaling: влияние на качество классификации	16
3.4 Эксперименты с узорными структурами	16
3.5 Лучшие FCA-конфигурации и роль узорных структур	18
4 Обсуждение	20
Заключение	22
Список использованных источников	22

Введение

Во многих прикладных задачах данные естественно задаются графом. Научные публикации цитируют друг друга, пользователи взаимодействуют в социальных сетях, белки образуют сети взаимодействий, а документы и веб-страницы соединяются ссылками. В таких данных метка объекта зависит не только от его собственных признаков, но и от окружения в графе. Поэтому для классификации узлов обычно нужны методы, которые одновременно используют атрибутивную и структурную информацию.

Одной из базовых архитектур такого типа является GraphSAGE. В отличие от ряда трансдуктивных подходов, GraphSAGE обучает параметризованную функцию агрегации соседских представлений, что делает его применимым к новым узлам и, в более общем случае, к новым графам [5]. Эта особенность особенно важна для задач классификации узлов в citation networks, где узлы соответствуют научным публикациям, рёбра задают отношения цитирования, а признаки узлов представляют текстовое содержание документов. На таких наборах данных, как Cora, CiteSeer и PubMed, GraphSAGE, GCN и GAT стали стандартными ориентирами для сравнения методов полунедзорной классификации узлов [3, 4, 6].

При этом результат GNN зависит не только от схемы message passing. Не менее важно, какие признаки получает модель и как они были подготовлены. Упрощённые feature-centric подходы, например SGC и SIGN, показывают, что заранее вычисленные или сглаженные признаки иногда дают конкурентное качество даже при более простой модели [7, 8]. Поэтому построение дополнительных признаков для GraphSAGE в этой работе рассматривается как часть метода, а не как нейтральный препроцессинг.

В настоящей работе рассматривается использование признаков, полученных из анализа формальных понятий (АФП, Formal Concept Analysis, FCA). FCA представляет данные в виде формального контекста: множества объектов, множества атрибутов и бинарного отношения принадлежности объекта атрибуту. На основе этого контекста строятся формальные понятия, каждое из которых задаётся объёмом объектов и содержанием атрибутов [2, 1]. С точки зрения машинного обучения формальные понятия можно рассматривать как интерпретируемые комбинации признаков. Если объект принадлежит объёму некоторого понятия, это означает, что он обладает соответствующим набором атрибутов. Следовательно, принадлежность объекта выбранным понятиям может быть использована как дополнительное признаковое представление.

Интерес к такой постановке связан с более широкой линией работ, в которой FCA используется не только как инструмент описательного анализа, но и как часть моделей машинного обучения. В частности, в работах С. О. Кузнецова и соавторов исследуется построение нейронных сетей на основе решёток формальных понятий [12]. В более современной работе С. О. Кузнецова и

М. Зуевой предложена модернизация такой архитектуры, FCA-CLNet, где предварительная кластеризация признаков используется для построения более компактной и интерпретируемой нейросетевой модели [13]. Эта линия исследований показывает, что формальные понятия могут выступать не только средством постфактум интерпретации, но и конструктивным элементом архитектуры или признакового пространства модели.

Другой важный аспект связан с отбором понятий. Полная решётка формальных понятий может быть слишком большой для непосредственного использования, поэтому в практических задачах необходимо выбирать ограниченное число наиболее полезных понятий. В работе М. Зуевой и С. О. Кузнецова исследуется влияние индексов интересности формальных понятий на качество нейросетей, построенных на основе концептных решёток. Рассматриваются, в частности, *basic level*, *target entropy*, Δ -*stability* и *lift* как критерии выбора понятий [14]. Для настоящей работы это особенно важно: мы также используем *top-K* отбор понятий и проверяем, как критерии выбора и способ построения формального контекста влияют на качество *downstream* классификации.

Несмотря на близость этих исследований, наша постановка отличается от FCA-CLNet. Мы не строим нейросетевую архитектуру непосредственно по решётке понятий и не заменяем GraphSAGE FCA-моделью. Вместо этого формальные понятия используются как дополнительные признаки узлов: для каждого выбранного понятия строится признак принадлежности узла его объёму, после чего такие признаки конкатенируются с исходными признаками и подаются на вход GraphSAGE. Тем самым работа проверяет более узкий, но практически важный вопрос: могут ли *concept-membership* признаки улучшить графовую нейронную сеть в задаче классификации узлов.

Ключевая методологическая трудность состоит в том, что улучшение качества после добавления FCA-признаков не обязательно означает полезность именно формально-понятийной структуры. Если к исходному признаковому описанию добавить K новых измерений, модель может выиграть просто из-за увеличения размерности или дополнительной линейной проекции признаков. Поэтому в настоящей работе FCA-признаки сравниваются не только с исходными признаками, но и с размерностно-согласованным SVD-контролем. Такой контроль позволяет отделить эффект добавленного признакового пространства от эффекта, связанного именно с формальными понятиями.

Вторая трудность связана с концептуальным шкалированием. Классический FCA работает с бинарным контекстом, тогда как признаки *citation networks* обычно являются разреженными или взвешенными текстовыми векторами. Наивное шкалирование *binary_nonzero*, где любой ненулевой признак считается активным атрибутом, может сводить понятия к одноатрибутным структурам. Тогда FCA-признаки становятся похожи на обычный отбор отдельных признаков и почти не используют связи между атрибутами. По этой причине *conceptual scaling* в работе вынесен в отдельную экспериментальную ось: кро-

ме наивного бинаризования рассматриваются квантильное шкалирование и локальный $\text{top-}k$ отбор признаков. После основной серии экспериментов эта линия была расширена до узорных структур (pattern structures): вместо бинарной принадлежности к атрибутам проверяются интервальные описания числовых признаков, soft membership и graph-aware построение интервалов.

Основной исследовательский вопрос работы формулируется следующим образом: *как способ описания объектов --- через бинарный формальный контекст или через узорные структуры --- влияет на полезность FCA-derived признаков и признаков узорных структур для GraphSAGE в задаче классификации узлов?* Этот вопрос объединяет две исследовательские линии: graph representation learning, где важны качество входных признаков и графовая агрегация, и FCA-based learning, где ключевую роль играют концептуальное шкалирование, отбор понятий, membership-функции и интерпретируемость получаемых структур.

Цель работы --- исследовать применимость признаков, полученных из анализа формальных понятий и узорных структур, в архитектуре GraphSAGE для задачи классификации узлов на citation-network датасетах Cora, CiteSeer и PubMed.

Для достижения цели решаются следующие задачи:

- 1) реализовать воспроизводимый экспериментальный конвейер GraphSAGE + FCA для задачи классификации узлов;
- 2) построить формальные контексты на основе признаков узлов и выделить формальные понятия;
- 3) сформировать concept-membership признаки и признаки принадлежности узорным структурам и использовать их как дополнение к исходным признакам GraphSAGE;
- 4) проверить hard и soft membership, а также graph-aware source для интервальных узорных структур;
- 5) сравнить GraphSAGE на исходных признаках, GraphSAGE с FCA-признаками, GraphSAGE с признаками узорных структур и GraphSAGE с SVD-контролем той же размерности;
- 6) исследовать влияние концептуального шкалирования на структуру формального контекста, включая размеры intents/extents, покрытие узлов и долю многоатрибутных понятий;
- 7) оценить, приводит ли более насыщенное шкалирование к улучшению качества классификации по сравнению с наивным FCA и SVD-контролем.

Объектом исследования являются методы классификации узлов в графах. Предметом исследования является влияние формально-понятийных признаков и признаков узорных структур, а также способов концептуального шкалирования и membership, на качество классификации в архитектуре GraphSAGE.

Основной вклад работы состоит в следующем. Реализован воспроизводимый экспериментальный конвейер, в котором FCA-derived признаки и признаки узорных структур добавляются к GraphSAGE и сравниваются с размерностно-согласованным SVD-контролем. На структурной диагностике показано, что `binary_nonzero` часто даёт почти только одноатрибутные понятия. Затем проверены более насыщенные варианты conceptual scaling, интервальные узорные структуры, soft membership и graph-aware source для построения узоров. Итоговый вывод остаётся условным: FCA-derived признаки и признаки узорных структур не являются универсальным усилением GraphSAGE. Они дают положительный результат на CiteSeer; graph-aware soft узорные признаки оказываются особенно сильными на PubMed; Cora остаётся пограничным случаем, где небольшой формальный выигрыш FCA над K-matched SVD не интерпретируется как устойчивое преимущество. Следовательно, полезность таких признаков определяется не самим фактом добавления понятий или узоров, а качеством описания объектов, способом задания membership и критерием отбора признаков.

Работа организована следующим образом. В разделе 1 рассматриваются связанные работы по графовым нейронным сетям, FCA, нейросетям на основе концептных решёток и концептуальному шкалированию. В разделе 2 описывается методология исследования: построение формального контекста, узорные структуры, отбор понятий, формирование дополнительных признаков, архитектура GraphSAGE и протокол оценки. В разделе 3 приводятся экспериментальные результаты на Cora, CiteSeer и PubMed. В разделе 4 обсуждаются полученные выводы, ограничения работы и возможные направления дальнейшего исследования.

1 Обзор связанных работ

1.1 Графовые нейронные сети и классификация узлов

Задача классификации узлов является одной из базовых задач машинного обучения на графах. В semi-supervised постановке метки доступны только для небольшой части узлов, однако модель может использовать как признаки всех узлов, так и структуру графа. Классические citation-network датасеты Cora, CiteSeer и PubMed получили широкое распространение после работ по полунаторному обучению на графах, в том числе Planetoid [3]. На этих данных были проверены многие архитектуры graph neural networks.

Одной из ключевых работ стала Graph Convolutional Network (GCN), где локальная графовая структура используется через нормализованное распространение признаков по соседям [4]. Позднее GraphSAGE предложил индуктивный механизм агрегации соседей, допускающий обучение функции представления, применимой к новым узлам [5]. GAT, в свою очередь, ввёл attention механизм для взвешивания соседей [6]. Вместе эти работы сформировали основу современной линии message passing neural networks.

Однако последующие исследования показали, что высокая эффективность GNN на citation-сетях во многом зависит от преобразования признаков. SGC упрощает GCN до предварительного сглаживания признаков и линейного классификатора, сохраняя конкурентное качество [7]. SIGN развивает эту идею, используя заранее вычисленные многомасштабные признаки и избегая дорогого neighbor sampling [8]. Эти результаты важны для настоящей работы: если сильные результаты могут быть получены за счёт преобразования признаков, то любые дополнительные признаки, включая FCA-derived features, должны сравниваться с сильными и честными признаковыми контролями.

1.2 FCA в машинном обучении и интерпретируемости

Formal Concept Analysis был предложен как математический аппарат для построения иерархий понятий на основе бинарных отношений между объектами и атрибутами [1, 2]. В машинном обучении FCA интересен тем, что формальные понятия задают одновременно группы объектов и разделяемые ими наборы признаков. Такая двойственная структура делает FCA естественным инструментом для интерпретируемого анализа данных, извлечения правил, концептуальной кластеризации и feature construction.

Современные обзоры и tutorial-работы подчёркивают, что FCA полезен не только как визуальный или логический аппарат, но и как источник интерпретируемых структур для downstream-задач [9, 10]. При этом практическое использование FCA ограничено двумя факторами. Во-первых, число формальных понятий может быть очень большим. Во-вторых, качество полученных понятий существенно зависит от того, как построен формальный контекст. Поэтому в

прикладных задачах необходимы методы отбора понятий и меры интересности. Работа С. О. Кузнецова и Т. Махаловой по interestingness measures формальных понятий показывает, что отбор понятий является центральной частью применимой FCA-методологии, а не вспомогательной процедурой [11].

Эта линия особенно близка к настоящей работе, поскольку мы не используем всю решётку понятий, а строим top- K набор FCA-признаков. Следовательно, итоговое качество зависит как от структуры формального контекста, так и от того, какие понятия выбраны для передачи в GraphSAGE. В этом смысле работа находится на стыке FCA-based feature construction и графового обучения.

1.3 Нейронные сети на основе формальных понятий

Связь FCA и нейросетевых моделей исследуется в ряде работ С. О. Кузнецова и соавторов. В работе о neural network architecture based on concept lattices предлагается строить архитектуру нейронной сети на основе концептной решётки [12]. В последующей работе С. О. Кузнецова и М. Зуевой предложена модернизация FCA-CLNet: признаки предварительно кластеризуются в семантически интерпретируемые группы, затем на основе полученного контекста выбираются устойчивые и интересные понятия, а по сокращённой решётке строится компактная нейросетевая архитектура [13]. Такой подход ориентирован на интерпретируемость и компактность модели при большом числе признаков.

Для настоящей работы эта линия важна по двум причинам. Во-первых, она показывает, что формальные понятия можно использовать как конструктивный элемент обучения, а не только как средство объяснения готовой модели. Во-вторых, она подчёркивает важность предварительной обработки признаков, отбора понятий и сокращения решётки. Наша работа развивает близкую идею в другой архитектурной среде: решётка понятий не задаёт структуру нейросети напрямую, а выбранные понятия превращаются в дополнительные признаки узлов для GraphSAGE.

Ещё более близкой к нашей экспериментальной логике является работа М. Зуевой и С. О. Кузнецова об индексах интересности для построения нейросетей на основе концептных решёток [14]. В ней сравниваются различные критерии выбора понятий, включая target entropy, lift и Δ -stability. Это напрямую мотивирует использование concept scorers и top- K selection в нашей работе. Различие состоит в том, что мы проверяем не FCA-архитектуру как таковую, а добавленную ценность concept-membership признаков в сильной графовой модели.

1.4 Концептуальное шкалирование и числовые признаки

Классический FCA работает с бинарными контекстами, но реальные данные часто содержат числовые, взвешенные или категориальные признаки. Поэтому перед построением формального контекста необходим этап концепту-

ального шкалирования. Для текстовых и citation-network данных это особенно существенно: признаки могут быть разреженными bag-of-words индикаторами или взвешенными TF--IDF-подобными величинами. Грубое преобразование ``ненулевой признак = активный атрибут" теряет информацию о величине веса признака и может радикально изменить структуру понятий.

В работах по numerical FCA подчёркивается, что переход от числовых признаков к бинарному контексту не является нейтральным. Он может приводить к потере информации, избыточному числу паттернов или, наоборот, к слишком грубым одноатрибутным структурам [15]. Более общие подходы, такие как узорные структуры и scale-measures, развивают FCA для сложных значений признаков и показывают, что выбор шкалирования должен рассматриваться как содержательная часть метода [16, 18].

Именно поэтому в настоящей работе conceptual scaling вынесен в отдельную экспериментальную ось. Мы сравниваем наивное шкалирование `binary_nonzero` с более насыщенными схемами: `quantile_global`, `topk_per_node` и `graph_smoothed_topk`. Это позволяет проверить, является ли слабость FCA-признаков следствием самого подхода или следствием неудачно построенного формального контекста.

1.5 Размерностные контроли

Если к исходному признаковому пространству добавить новые признаки, то улучшение качества может возникнуть просто из-за увеличения размерности входа. Поэтому сравнение FCA-признаков только с raw GraphSAGE недостаточно. Необходим контроль, который добавляет такое же число признаков, но не использует формально-понятийную структуру. В настоящей работе таким контролем является SVD: к исходным признакам добавляется K -мерное низкоранговое представление той же ширины, что и набор FCA-признаков.

Использование SVD-контроля согласуется с общей линией feature-centric GNN. Если SVD той же размерности даёт качество, сопоставимое с FCA, то выигрыш нельзя уверенно приписать именно понятиям. Напротив, если FCA превосходит SVD при сопоставимой размерности, это является более сильным аргументом в пользу содержательной роли концептуальных признаков. Такая постановка делает экспериментальное сравнение более строгим и уменьшает риск переинтерпретации результатов.

2 Методология исследования

2.1 Постановка задачи

В работе рассматривается задача классификации узлов в графе. Пусть задан граф $G = (V, E)$, где V --- множество узлов, E --- множество рёбер. Каждому узлу $v \in V$ соответствует вектор признаков $x_v \in \mathbb{R}^d$. Для части узлов известны метки классов $y_v \in \{1, \dots, C\}$. Необходимо построить модель, которая по признакам узлов и структуре графа предсказывает метки тестовых узлов.

В citation-network датасетах узлы соответствуют научным публикациям, а рёбра --- отношениям цитирования. Признаки узлов представляют текстовое содержание документов. Все эксперименты проводятся в full-batch transductive постановке со стандартным public-разбиением на train, validation и test. Общая схема используемого конвейера показана на рис. 1: исходные признаки узлов проходят через блок построения FCA-derived признаков или признаков узорных структур, затем объединяются с исходным представлением и подаются в GraphSAGE.




Рис. 1. Схема объединения исходных признаков, FCA-derived признаков, признаков узорных структур и GraphSAGE

2.2 GraphSAGE

В качестве основной графовой архитектуры используется двухслойный GraphSAGE с mean aggregation. На каждом слое представление узла обновляется на основе его текущего состояния и агрегированного представления соседей.

Агрегация и обновление задаются формулами (1) и (2):

$$h_{\mathcal{N}(v)}^{(k)} = \text{mean} \left(\{h_u^{(k-1)} : u \in \mathcal{N}(v)\} \right), \quad (1)$$

$$h_v^{(k)} = \sigma \left(W^{(k)} \cdot \left[h_v^{(k-1)} \parallel h_{\mathcal{N}(v)}^{(k)} \right] \right), \quad (2)$$

где $\mathcal{N}(v)$ --- множество соседей узла, $\parallel$ обозначает конкатенацию, $W^{(k)}$ --- обучаемая матрица, σ --- нелинейность.

В экспериментах используется конфигурация: два слоя, 128 скрытых признаков, dropout 0.5, Adam с learning rate 0.005 и weight decay $5 \cdot 10^{-4}$. Обучение проводится до 300 эпох с early stopping по validation accuracy.

2.3 Построение формального контекста

Для применения FCA исходные признаки узлов преобразуются в бинарный формальный контекст, заданный формулой (3):

$$\mathbb{K} = (G, M, I), \quad (3)$$

где G --- множество объектов, в данной работе узлов графа; M --- множество атрибутов; $I \subseteq G \times M$ --- бинарное отношение принадлежности объекта атрибуту.

Для подмножества объектов $A \subseteq G$ и подмножества атрибутов $B \subseteq M$ операторы Галуа определяются формулами (4) и (5):

$$A' = \{m \in M \mid \forall g \in A : (g, m) \in I\}, \quad (4)$$

$$B' = \{g \in G \mid \forall m \in B : (g, m) \in I\}. \quad (5)$$

Формальным понятием называется пара (A, B) такая, что $A' = B$ и $B' = A$. Множество A называется объёмом понятия, а множество B --- содержанием.

2.4 Концептуальное шкалирование

В работе сравниваются несколько способов построения бинарного контекста. Базовый вариант `binary_nonzero` задаёт атрибут как активный, если соответствующее значение признака не равно нулю, как показано в формуле (6):

$$I(g, m_j) = 1[x_{gj} \neq 0]. \quad (6)$$

В режиме `quantile_global` для каждого признака вычисляется порог по квантилю q на обучающих узлах, после чего атрибут активируется по формуле (7), если значение признака не ниже этого порога:

$$I(g, m_j) = 1[x_{gj} \geq Q_j(q)]. \quad (7)$$

В экспериментах используются $q = 0.90$ для Cora и CiteSeer и $q = 0.75$ для PubMed.

В режиме `topk_per_node` для каждого узла активируются только k наибольших положительных признаков. Такой способ уменьшает число активных атрибутов на объект и делает контекст более разреженным. Наконец, `graph_smoothed_topk` сначала сглаживает признаки по соседям графа по формуле (8):

$$X_{\text{smooth}} = \alpha X + (1 - \alpha) \hat{A} X, \quad (8)$$

где $\hat{A}$ --- нормализованная матрица смежности, после чего применяется *top-k* шкалирование.

2.5 Узорные структуры

Бинарный формальный контекст удобен для классического FCA, но он неизбежно теряет часть информации о числовых признаках. Поэтому дополнительно была проверена более общая постановка на основе узорных структур [16]. В ней объекту сопоставляется не множество бинарных атрибутов, а более сложное описание. В работе используется интервальный вариант узорных структур: описание задаётся набором признаков и интервалами допустимых значений для каждого из них.

Пусть для выбранного узора P_j заданы признаки F_j и интервалы $[l_{jf}, u_{jf}]$ для каждого $f \in F_j$. Узел принадлежит extent такого узора, если его значения попадают во все соответствующие интервалы:

$$z_{vj}^{\text{pat}} = \mathbb{I}(\forall f \in F_j : l_{jf} \leq x_{vf} \leq u_{jf}). \quad (9)$$

Интервалы строятся по квантильным бином, вычисленным на обучающих узлах. Кандидаты узорных структур генерируются из выборки объектов: для каждого объекта берутся несколько наиболее активных признаков, после чего соответствующие значения заменяются интервалами квантильной сетки. Затем узорные структуры фильтруются по *support*, ранжируются теми же критериями *support* или *target entropy* и превращаются в дополнительные признаки по формуле (9). Помимо *hard membership* проверяется *soft membership*: вместо бинарного попадания в интервал используется степень близости значения к центру интервала. Также рассматривается *graph-aware* вариант, где интервалы строятся не по исходным признакам, а по смеси исходных и сглаженных по соседям признаков. Этот вариант проверяет, помогает ли более общее числовое описание объектов там, где бинарный FCA оказывается слишком грубым.

2.6 Отбор понятий и FCA-признаки

После построения контекста извлекаются формальные понятия, затем они ранжируются по функции оценки. В работе используются несупервизор-

ный критерий support и супервизорный критерий target entropy. Супервизорные оценки вычисляются только по обучающим узлам, чтобы исключить утечку информации из тестовой выборки.

Из выбранных K понятий строится матрица принадлежности узлов понятиям (формула (10)):

$$z_v = [\mathbb{I}(v \in \text{Ext}(C_1)), \dots, \mathbb{I}(v \in \text{Ext}(C_K))] . \quad (10)$$

Итоговый вход модели задаётся конкатенацией исходных признаков и FCA-признаков согласно формуле (11):

$$\tilde{x}_v = x_v \parallel z_v. \quad (11)$$

2.7 SVD-контроль и протокол оценки

Для контроля эффекта добавленной размерности используется SVD-представление исходных признаков той же ширины K . Низкоранговые представления такого типа широко применяются в анализе текстовых признаков, включая latent semantic analysis [19]. В этом варианте на вход GraphSAGE подаётся конкатенация исходных признаков и K SVD-компонент. Такой контроль позволяет проверить, превосходят ли FCA-признаки простое низкоранговое расширение признакового пространства.

Все результаты усредняются по пяти random seeds: 0, 1, 2, 3, 4. Основные метрики --- test accuracy и macro-F1. Дополнительно анализируется accuracy на узлах малой степени, но эта метрика используется только как вспомогательная. Конфигурация считается успешной, если она превосходит K-matched SVD более чем на 0.002 accuracy; если она превосходит только binary_nonzero FCA, но не SVD, результат считается частичным.

2.8 Воспроизводимость экспериментов

Эксперименты организованы как конфигурационный конвейер: параметры датасетов, моделей, шкалирования и сеток перебора вынесены в YAML-файлы, а итоговые таблицы строятся из per-seed результатов. Код экспериментов и файлы конфигурации доступны в репозитории: <https://github.com/agiccoder/graphsage-fca-coursework>. Для финальных сравнений используются только зафиксированные запуски по seeds 0--4 и public-разбиения Cora, CiteSeer и PubMed. При построении таблиц richer scaling отделяется от binary_nonzero по режиму бинаризации и его параметрам, а SVD-сравнение проводится при том же числе добавленных признаков K . Такая схема нужна, чтобы не смешивать разные варианты шкалирования и не завышать эффект FCA-признаков за счёт нестрогой агрегации.

3 Экспериментальные результаты

3.1 Датасеты и базовые результаты

В экспериментах используются три стандартных датасета: Cora, CiteSeer и PubMed. Их основные характеристики приведены в табл. 1.

Таблица 1. Характеристики используемых датасетов

Датасет	Узлы	Рёбра	Признаки	Классы	Train	Val	Test
Cora	2708	10556	1433	7	140	500	1000
CiteSeer	3327	9104	3703	6	120	500	1000
PubMed	19717	88648	500	3	60	500	1000

Сначала сравнивались raw GraphSAGE, MLP, GCN, наивный вариант GraphSAGE + FCA при `binary_nonzero` и SVD-контроль той же размерности $K = 128$. Результаты приведены в табл. 2.

Таблица 2. Основные результаты при $K = 128$

Датасет	Вариант	Accuracy	Macro-F1	Low-degree acc.
Cora	GraphSAGE raw	0.8008	0.7929	0.7535
Cora	FCA binary, support	0.8010	0.7958	0.7525
Cora	SVD control	0.8116	0.8062	0.7605
CiteSeer	GraphSAGE raw	0.6832	0.6426	0.6121
CiteSeer	FCA binary, support	0.6924	0.6585	0.6222
CiteSeer	SVD control	0.6924	0.6569	0.6158
PubMed	GraphSAGE raw	0.7658	0.7613	0.7561
PubMed	FCA binary, support	0.6784	0.6911	0.6506
PubMed	SVD control	0.7616	0.7560	0.7510

Наивный FCA-вариант показывает неоднородные результаты. На CiteSeer он улучшает raw GraphSAGE и достигает уровня SVD-контроля. На Cora результат близок к raw GraphSAGE, но уступает SVD. На PubMed наблюдается существенное ухудшение: ассурасу падает с 0.7658 до 0.6784. На рис. 2 видно, что даже в базовом сравнении SVD является сильным ориентиром для FCA-признаков. Это указывает на то, что простое добавление FCA-признаков не является универсальным улучшением.




Рис. 2. Test accuracy для основных вариантов GraphSAGE, FCA и SVD-контроля

3.2 Структура формальных контекстов

Для объяснения поведения FCA-признаков была проведена структурная диагностика формальных контекстов. В табл. 3 сравниваются `binary_nonzero` и более насыщенные способы шкалирования.

Таблица 3. Структурная диагностика формальных контекстов

Датасет	Шкалирование	Mean intent	Multi-attr	Coverage	Mean extent
Cora	binary	1.039	0.039	0.992	180.9
Cora	quantile $q=0.90$	2.180	0.875	0.918	129.5
CiteSeer	binary	1.000	0.000	0.996	280.4
CiteSeer	quantile $q=0.90$	1.773	0.688	0.988	188.5
PubMed	binary	1.000	0.000	1.000	3921.7
PubMed	quantile $q=0.75$	2.211	0.742	0.999	1784.7
PubMed	top-k, $k=10$	1.000	0.000	0.995	715.8

Из таблицы видно, что `binary_nonzero` почти всегда приводит к одноатрибутным понятиям: доля многоатрибутивных понятий равна нулю на CiteSeer и PubMed и составляет лишь 0.039 на Cora. Квантильное шкалирование, напротив, создаёт более богатый контекст: доля многоатрибутивных понятий достигает 0.688 на CiteSeer и 0.742 на PubMed. Это подтверждает, что проблема наивного FCA связана не только с GraphSAGE, но и с построением формального контекста.

3.3 Richer scaling: влияние на качество классификации

Далее проверялось, приводит ли более богатая структура контекста к улучшению качества классификации. Основные результаты приведены в табл. 4.

Таблица 4. Результаты richer conceptual scaling

Датасет	Scaling	Scorer	K	FCA	SVD	Δ к SVD
Cora	quantile $q=0.90$	support	128	0.7920	0.8116	-0.0196
Cora	quantile $q=0.90$	target entropy	128	0.7928	0.8116	-0.0188
CiteSeer	quantile $q=0.90$	support	128	0.7028	0.6924	0.0104
CiteSeer	quantile $q=0.90$	target entropy	128	0.6960	0.6924	0.0036
CiteSeer	quantile $q=0.90$	support	256	0.7078	0.6870	0.0208
CiteSeer	quantile $q=0.90$	target entropy	256	0.7108	0.6870	0.0238
PubMed	quantile $q=0.75$	support	128	0.7372	0.7616	-0.0244
PubMed	top-k, $k=10$	support	128	0.7510	0.7616	-0.0106
PubMed	graph-smoothed top-k	support	128	0.7394	0.7616	-0.0222

Самый убедительный положительный результат получен на CiteSeer. Квантильное шкалирование при $q = 0.90$ превосходит SVD-контроль той же размерности как при $K = 128$, так и при $K = 256$. Лучший результат среди этих запусков достигается для target entropy при $K = 256$: accuracy равна 0.7108 против 0.6870 у K-matched SVD-контроля и 0.6832 у raw GraphSAGE. При этом важно не смешивать два сравнения: лучший SVD по всей сетке на CiteSeer немного выше (0.7116), поэтому речь идёт именно о выигрыше над контролем при том же числе добавленных признаков.

На PubMed richer scaling существенно улучшает наивный FCA. Например, topk_per_node при $K = 128$ повышает accuracy с 0.6784 до 0.7510. Однако этот результат всё ещё ниже raw GraphSAGE и SVD-контроля. Следовательно, для PubMed richer scaling исправляет часть проблемы формального контекста, но не делает FCA-признаки конкурентными с низкоранговым линейным представлением.

На Cora более насыщенное шкалирование не помогает. Лучший результат среди FCA-вариантов для Cora достигается не richer scaling, а наивным binary_nonzero с target entropy: 0.8144, что практически соответствует лучшему SVD-контролю, но не даёт устойчивого преимущества над ним.

3.4 Эксперименты с узорными структурами

Отдельно была проведена проверка интервальных узорных структур. Цель этого эксперимента состояла не в полной замене основного FCA-grid, а

в проверке более общего способа описания числовых признаков. Использовались квантильная сетка из четырёх интервалов и узоры размера 2. После первоначального hard-варианта были дополнительно проверены soft membership, graph-aware source, где интервалы узоров строятся по признакам, сглаженным по соседям графа, а также небольшой K-sweep для $K \in \{64, 128, 256\}$. Основные результаты приведены в табл. 5.

Таблица 5. Ключевые результаты для интервальных узорных структур

Датасет	Pattern-вариант	Scorer	K	Pattern	SVD	Δ	95% CI
Cora	graph-aware soft	target entropy	128	0.8006	0.8116	-0.0110	[-0.0214; 0.0004]
CiteSeer	interval hard	support	128	0.6800	0.6924	-0.0124	[-0.0184; -0.0060]
CiteSeer	interval soft	support	128	0.6914	0.6924	-0.0010	[-0.0168; 0.0148]
CiteSeer	graph-aware soft	target entropy	128	0.6988	0.6924	0.0064	[-0.0038; 0.0178]
CiteSeer	graph-aware soft	target entropy	256	0.6936	0.6870	0.0066	[0.0008; 0.0124]
PubMed	interval hard	target entropy	128	0.6890	0.7616	-0.0726	[-0.0758; -0.0696]
PubMed	interval soft	support	128	0.7596	0.7616	-0.0020	[-0.0070; 0.0036]
PubMed	graph-aware soft	target entropy	128	0.7672	0.7616	0.0056	[0.0014; 0.0104]
PubMed	graph-aware soft	target entropy	256	0.7794	0.7614	0.0180	[0.0126; 0.0228]

Результаты показывают, что простые hard interval узоры сами по себе не помогают: на Cora, CiteSeer и PubMed они уступают SVD-контролю. Soft membership заметно исправляет ситуацию, особенно на PubMed: interval soft повышает accuracy до 0.7596 и практически достигает SVD-контроля. Самый сильный вариант получается при совмещении graph-aware source и soft membership. На CiteSeer положительный эффект есть, но он небольшой: при $K = 128$ доверительный интервал для разности с SVD пересекает ноль, а при $K = 256$ становится положительным. На PubMed эффект заметнее: graph-aware soft вариант при $K = 256$ достигает accuracy 0.7794 против 0.7614 у K-matched SVD и 0.7658 у raw GraphSAGE. Значит, узорные структуры сработали не в базовом hard-варианте, а после добавления мягкой принадлежности, учёта графового окружения и настройки числа признаков узорных структур. На рис. 3 отдельно показано, как основные варианты узорных структур при $K = 128$ отличаются от K-matched SVD.




Рис. 3. Разность ассигасу между признаками узорных структур и K-matched SVD при $K = 128$

3.5 Лучшие FCA-конфигурации и роль узорных структур

В табл. 6 приведены лучшие FCA-конфигурации для каждого датасета.

Таблица 6. Лучшие FCA-конфигурации по датасетам

Датасет	Лучшая FCA-конфигурация	FCA	Raw	Best SVD
Cora	binary, target entropy, $K = 128$	0.8144	0.8008	0.8120
CiteSeer	quantile q=0.90, target entropy, $K = 256$	0.7108	0.6832	0.7116
PubMed	top-k, support, $K = 128$	0.7510	0.7658	0.7658

Таблица 6 учитывает только FCA-конфигурации, построенные через бинарный формальный контекст и richer conceptual scaling. Если дополнительно учитывать признаки узорных структур, то для PubMed лучшим результатом становится graph-aware soft вариант при $K = 256$ с ассигасу 0.7794, что выше raw GraphSAGE и K-matched SVD. Этот результат рассматривается как отдельная ветка, поскольку табл. 6 относится только к FCA-конфигурациям.

Эти результаты не поддерживают простой тезис «FCA улучшает GraphSAGE». Эффект зависит от датасета, шкалирования и отбора понятий. На CiteSeer richer scaling выигрывает у SVD при фиксированном K , хотя лучший SVD по сетке остаётся практически на том же уровне. На PubMed более богатое шкалирование улучшает только FCA-семейство относительно наивного контекста. На Cora оно не даёт прироста качества. На рис. 4 показана только FCA-ветка экспериментов, то есть результаты richer conceptual scaling без interval pattern structures. Поэтому PubMed на рисунке остаётся ниже SVD, хотя graph-aware soft варианты узорных структур в табл. 5 дают другой результат.




Рис. 4. Разность ассигасы между richer FCA и SVD-контролем без узорных структур

4 Обсуждение

Эксперименты показывают, что FCA-признаки ведут себя по-разному на разных датасетах. Они не работают как готовая добавка, которая автоматически усиливает GraphSAGE: простое добавление признаков принадлежности формальным понятиям иногда почти ничего не меняет, а иногда заметно ухудшает результат. На PubMed это видно особенно хорошо: `binary_nonzero` FCA сильно уступает `raw` GraphSAGE. Такие отрицательные случаи важны для работы, потому что они не дают свести результат к простой мысли «добавили признаков --- стало лучше».

Причина не сводится к самой архитектуре GraphSAGE. Структурная диагностика показывает, что наивное бинарирование почти полностью сводит понятия к одноатрибутным структурам. В таком виде FCA-признаки становятся близки к отбору отдельных исходных признаков и теряют то, ради чего вообще используется FCA: описание групп объектов через совместные наборы атрибутов. Квантильное шкалирование исправляет структуру контекста: появляются многоатрибутные понятия, а `extents` становятся меньше. Но это ещё не гарантирует рост ассурасы. Проверка узорных структур уточняет этот вывод: `hard interval descriptions` также не достаточны, зато `soft membership` и `graph-aware` построение интервалов помогают на CiteSeer и особенно на PubMed.

Именно поэтому в работе нужен SVD-контроль. Если сравнивать только с `raw` GraphSAGE или с наивным FCA, вклад формальных понятий легко переоценить. `K-matched SVD` показывает, какая часть эффекта может быть связана просто с добавлением новых измерений. По этой более строгой проверке для классических FCA-признаков положительный результат остаётся прежде всего на CiteSeer: `richer` FCA превосходит SVD при одинаковом K . На PubMed такие FCA-признаки не превосходят SVD; на Cora лучший FCA-вариант формально выше `K-matched SVD`, но разрыв мал и интерпретируется как пограничный, а не как устойчивый положительный результат. Узорные структуры образуют отдельный `exploratory case`: `graph-aware soft` варианты оказываются конкурентными с SVD на CiteSeer и превосходят SVD на PubMed при $K = 256$.

По отношению к FCA-CLNet эта работа занимает более осторожную позицию. В FCA-CLNet формальные понятия задают структуру нейросети, а здесь они используются как дополнительные признаки для уже существующей графовой модели. Такой вариант архитектурно проще, зато позволяет отдельно проверить добавленную ценность `concept-membership` признаков. Результаты говорят не о том, что FCA всегда полезен для GNN, а о том, что он может быть полезен при удачном шкалировании и подходящем датасете. Эксперимент с узорными структурами показывает похожую границу. Само интервальное описание ещё не решает проблему отбора полезных признаков для GraphSAGE, но мягкая принадлежность и `graph-aware` построение интервалов делают такие признаки конкурентными на CiteSeer и PubMed.

Возможное объяснение различий между датасетами состоит в балансе между специфичностью понятий и покрытием узлов. На CiteSeer квантильное шкалирование увеличивает долю многоатрибутных понятий при высоком покрытии. На Cora richer scaling, судя по результатам, делает признаки менее полезными для классификатора, а на PubMed даже улучшенные контексты остаются недостаточно конкурентными по сравнению с raw и SVD-признаками. Это объяснение требует отдельной проверки и в данной работе рассматривается как гипотеза, а не как доказанный причинный механизм.

Работа имеет несколько ограничений. Во-первых, эксперименты проводились только на трёх citation-network датасетах, поэтому выводы нельзя напрямую переносить на другие типы графов. Во-вторых, использовалась относительно простая GraphSAGE-архитектура, поскольку целью было изучить влияние признаков, а не достичь максимального качества. В-третьих, интерпретация самих понятий ограничена тем, что признаки Planetoid-датасетов не всегда имеют легко восстанавливаемые семантические имена. Отдельным ограничением является малое число random seeds. В работе сравниваются средние значения по пяти запускам; доверительные интервалы приведены только для экспериментов с узорными структурами, а систематической проверки значимости по всем конфигурациям и датасетам не проводилось. Поэтому небольшие разрывы между конфигурациями, особенно на Cora и CiteSeer, следует интерпретировать осторожно. Эксперимент с узорными структурами также ограничен: использовались фиксированный размер узора и фиксированная квантильная сетка, а K-sweep был проведён только для CiteSeer и PubMed. Наконец, хотя richer scaling и graph-aware soft варианты дают более сильные признаки, остаётся открытым вопрос о более сложных узорных структурах и устойчивых понятиях, которые могут оказаться более информативными.

Дальше эту линию стоит развивать не как простой переход к узорным структурам --- он уже сделан в базовом interval-варианте, --- а как поиск более удачных узорных описаний и критериев отбора. В первую очередь интересны меры устойчивости, включая Δ -stability [17], интервалы переменной ширины, graph-aware отбор узоров и проверка на гетерофильных графах. Отдельно полезны датасеты, где признаки имеют понятную семантику: на них можно оценивать не только ассигасу, но и содержательность найденных понятий.

Заключение

В работе исследована возможность использовать признаки, полученные из анализа формальных понятий и узорных структур, для улучшения GraphSAGE в задаче классификации узлов. Построен экспериментальный конвейер, в котором из признаков узлов формируется бинарный формальный контекст или интервальное описание объекта, после чего выбранные concept-membership признаки и признаки принадлежности узорным структурам добавляются к исходному представлению узла.

Полученные результаты показывают, что FCA-derived признаки и признаки узорных структур не являются универсальным усилением GraphSAGE. Для классического бинарного FCA устойчивый положительный результат наблюдается прежде всего на CiteSeer; на Cora результат остаётся пограничным, поскольку лучший FCA-вариант лишь немного превышает K-matched SVD и не даёт устойчивого преимущества. Проверка интервальных узорных структур показывает, что более гибкое числовое описание объектов, особенно в сочетании с soft membership и graph-aware source, может быть конкурентным с SVD-контролем на CiteSeer и превосходить его на PubMed при $K = 256$. Поэтому главный фактор успеха состоит не в самом факте использования FCA, а в качестве описания объектов, способе задания membership и критерии отбора признаков.

В дальнейшем эту линию стоит развивать через более аккуратный отбор устойчивых понятий и узоров, интервалы переменной ширины и расширенные graph-aware варианты шкалирования. Отдельно полезна проверка на датасетах с более понятной семантикой признаков: там можно оценивать не только ассигасу, но и содержательную интерпретируемость найденных понятий.

Список использованных источников

- [1] Wille R. Restructuring lattice theory: An approach based on hierarchies of concepts // *Ordered Sets*. Dordrecht: Springer, 1982. P. 445--470.
- [2] Ganter B., Wille R. *Formal Concept Analysis: Mathematical Foundations*. Berlin: Springer, 1999.
- [3] Yang Z., Cohen W. W., Salakhutdinov R. Revisiting Semi-Supervised Learning with Graph Embeddings // *International Conference on Machine Learning*. 2016. P. 40--48.
- [4] Kipf T. N., Welling M. Semi-Supervised Classification with Graph Convolutional Networks // *International Conference on Learning Representations*. 2017.
- [5] Hamilton W. L., Ying R., Leskovec J. Inductive Representation Learning on Large Graphs // *Advances in Neural Information Processing Systems*. 2017.
- [6] Veličković P., Cucurull G., Casanova A., Romero A., Liò P., Bengio Y. Graph Attention Networks // *International Conference on Learning Representations*. 2018.
- [7] Wu F., Zhang T., Souza A. H., Fifty C., Yu T., Weinberger K. Q. Simplifying Graph Convolutional Networks // *International Conference on Machine Learning*. 2019. P. 6861--6871.
- [8] Frasca F., Rossi E., Eynard D., Chamberlain B., Bronstein M., Monti F. SIGN: Scalable Inception Graph Neural Networks // *ICML Workshop on Graph Representation Learning and Beyond*. 2020.
- [9] Ignatov D. I. Introduction to Formal Concept Analysis and Its Applications in Information Retrieval and Related Fields // *Russian Summer School in Information Retrieval*. 2017.
- [10] Kwuida L., Sertkaya B. Formal Concept Analysis in Machine Learning and Knowledge Discovery // *Concept Lattices and Their Applications*. 2021.
- [11] Kuznetsov S. O., Makhlova T. On interestingness measures of formal concepts // *Information Sciences*. 2018. Vol. 442--443. P. 202--219.
- [12] Kuznetsov S. O., Makhazhanov N., Ushakov M. On Neural Network Architecture Based on Concept Lattices // *Foundations of Intelligent Systems: 23rd International Symposium, ISMIS 2017*. Springer, 2017. P. 653--663.

- [13] Kuznetsov S. O., Zueva M. Training Neural Networks Based on Formal Concepts // FCA4AI@ECAI. 2024. P. 39--46.
- [14] Zueva M., Kuznetsov S. O. Interestingness Indices for Building Neural Networks Based on Concept Lattices // Automation and Remote Control. 2024. Vol. 85. No. 3. P. 297--304.
- [15] Kaytoue M., Kuznetsov S. O., Napoli A. Revisiting Numerical Pattern Mining with Formal Concept Analysis // Proceedings of the Twenty-Second International Joint Conference on Artificial Intelligence. 2011.
- [16] Ganter B., Kuznetsov S. O. Pattern Structures and Their Projections // Conceptual Structures: Broadening the Base. Berlin: Springer, 2001. P. 129-142.
- [17] Buzmakov A., Kuznetsov S. O., Napoli A. Scalable Estimates of Concept Stability // Formal Concept Analysis: 12th International Conference, ICFCA 2014. Springer, 2014. P. 157--172.
- [18] Hanika T., Hirth J. Scale-measures for Formal Concept Analysis // International Conference on Formal Concept Analysis. 2021.
- [19] Deerwester S., Dumais S. T., Furnas G. W., Landauer T. K., Harshman R. Indexing by latent semantic analysis // Journal of the American Society for Information Science. 1990. Vol. 41, No. 6. P. 391--407.